

Performance & coûts

Mesurer avant de dimensionner — préserver qualité et marge

OBJECTIFS DE PILOTE · AUCUN BENCHMARK ACQUIS

Définir la charge utile

La charge se décrit par opérations et volumes, pas par le seul nombre d’inscrits.

Scénario proposé	Dimensionnement du test
Pilote	3 cabinets, 2 à 10 recruteurs chacun, jusqu’à 1 000 profils par cabinet.
Interactif	20 sessions simulées ; montée à 10 requêtes/seconde pendant 15 minutes après échauffement.
Import simultané	3 lots de 100 PDF conformes aux limites de 10 Mo et 30 pages ; tailles réelles consignées.
IA	3 lots de 50 brouillons ; concurrence plafonnée et attente mesurée séparément du calcul.
Étape suivante	Rejouer à 10 fois le volume après réussite ; aucune extrapolation à 500 000 utilisateurs.

Objectifs internes initiaux

- API courante hors transfert et IA : p95 inférieur à 500 ms, moins de 1 % de réponses 5xx sous charge interactive.
- Comparaison d’une mission avec 1 000 profils déjà indexés du cabinet : p95 inférieur à 2 secondes.
- PDF textuel : traitement p95 inférieur à 60 secondes ; brouillon : p95 inférieur à 30 secondes. Mesurer aussi le délai total avec attente.
- Navigation disponible pendant les imports ; progression et erreurs visibles.

RÈGLE DE PUBLICATION

Conserver date, commit, matériel, région, modèles, corpus et paramètres. Afficher p50, p95, taux d’échec et coût. Un résultat de laboratoire n’est pas une garantie de production.

Performance & coûts

Mesurer avant de dimensionner — préserver qualité et marge

OBJECTIFS DE PILOTE · AUCUN BENCHMARK ACQUIS

Optimiser le pipeline dans le bon ordre

Réduire les traitements inutiles avant de changer d'infrastructure.

1 • Ingestion une seule fois

Calculer une empreinte dans le périmètre du cabinet, extraire texte puis profil. Réutiliser uniquement les sorties du même document et de la même version de parseur. Détecter les doublons sans mutualiser les viviers privés.

2 • Recherche puis justification

Appliquer les critères professionnels explicites, puis combiner recherche textuelle et proximité sémantique. Comparer à une référence par mots-clés. Réserver l'IA générative à la synthèse des preuves et, si les mesures le justifient, à une réévaluation d'un petit ensemble. Aucun score n'est une probabilité de réussite.

3 • Stockage et cache

PostgreSQL est proposé ; pgvector est une option. Vérifier rappel et temps avec filtres de cabinet : un index approximatif filtré peut retourner trop peu de résultats. Commencer par un calcul exact sur les petits viviers ; indexer selon les mesures. [VECTOR]

CACHE PERSONNALISÉ

Organisation + profil/version + mission/version + modèle + version de consigne + méthode. Contrôler les droits avant lecture. Ne jamais réutiliser une analyse individuelle provenant d'un autre cabinet.

4 • Travail asynchrone

Un worker absorbe parsing et génération. Redis/BullMQ est proposé pour la file ; NestJS fournit une intégration. Limiter concurrence par cabinet et globale, réserver les quotas avant lancement et exposer l'attente. [QUEUE]

[VECTOR] [pgvector](#) — [documentation officielle](#), [index et filtres](#) · consulté le 06/09/2026.

[QUEUE] [NestJS](#) — [files de traitement BullMQ](#) · consulté le 06/09/2026.

Performance & coûts

Mesurer avant de dimensionner — préserver qualité et marge

OBJECTIFS DE PILOTE · AUCUN BENCHMARK ACQUIS

Économie unitaire avant abonnement

Simulation de gestion, sans tarif fournisseur ni prévision de ventes.

FORMULES

Coût direct = inférence + extraction + stockage + infrastructure allouée + paiement + support variable.
Contribution = revenu HT – coût direct.
Taux de contribution = contribution / revenu HT.

Exemple à 299 € HT/mois	Budget supposé
Inférence et extraction	18 €
Stockage et sauvegardes	4 €
Infrastructure allouée	12 €
Paieement : hypothèse, pas tarif fournisseur	6 €
Support : 30 min à 40 €/h	20 €
Total des coûts directs	60 €
Contribution avant frais fixes et acquisition	239 €, soit 79,9 %

Avec 3 000 € de coûts fixes mensuels supplémentaires, 13 abonnements de ce type les couvriraient (3 000 / 239, arrondi au supérieur). Ce n’est pas un seuil réel avant budget complet : rémunération, acquisition, remboursements, attrition et charges. Ne pas compter deux fois une charge déjà allouée.

Instrumentation commerciale

- Enregistrer coût et volume par traitement, modèle et cabinet sans contenu personnel dans les journaux.
- Mesurer le coût par profil utilisable et par synthèse acceptée, pas seulement par appel IA.
- Objectif proposé : contribution d’au moins 70 % ; alerte si les coûts directs dépassent 30 % du revenu HT.
- Au quota, arrêter les nouvelles tâches coûteuses et garder lecture/export. Aucun dépassement facturé sans accord explicite.

Performance & coûts

Mesurer avant de dimensionner — préserver qualité et marge

OBJECTIFS DE PILOTE · AUCUN BENCHMARK ACQUIS

Quand changer de taille ou de modèle

Un incident ne se résout pas automatiquement en ajoutant des machines.

Signal	Action avant migration
File trop longue	Limiter concurrence, identifier le fournisseur lent, répartir les workers.
SQL lent	Examiner plans, index, filtres et volumes ; comparer exact/approximatif.
IA coûteuse	Réduire contextes, réutiliser sorties valides, plafonner régénérations et comparer modèles.
Parsing CPU	Profiler, isoler le processus, mesurer une implémentation optimisée.
GPU envisagé	Comparer coût complet aux API pour plusieurs taux d’occupation à qualité égale.

API ou auto-hébergement

Inclure GPU, inactivité, exploitation, supervision, redondance et secours. Le local évite une facturation au token externe mais mobilise matériel et énergie. Aucun gain $\times 10$ ou $\times 50$ sans test comparable. Évaluer licences et flux de données avant choix du modèle.

Résilience proposée

- Au plus 3 tentatives pour panne transitoire avec temporisation ; aucune reprise automatique pour fichier invalide ou quota épuisé.
- Tâches idempotentes : une reprise ne crée pas un second résultat ni une seconde facturation. [JOBS]
- RPO 24 h et RTO 4 h : objectifs internes à confirmer par restauration testée, pas SLA implicite.
- Suivre ancienneté des jobs, coût, erreurs et fraîcheur. Chaque alerte désigne un responsable et une action.

[JOBS] BullMQ — tâches idempotentes · consulté le 06/09/2026.

DÉCISION À CHAQUE PALIER

Poursuivre si qualité, isolation et coût restent acceptables. Sinon réduire le périmètre ou revoir le prix avant d’élargir les volumes.