

Architecture progressive

Archive historique — Un socle modulaire, des évolutions justifiées par les mesures

ARCHIVÉ · HORS PÉRIMÈTRE B2C

Partir du code réel

Remplacer une migration prématurée Rust/Go par une trajectoire de livraison et d’exploitation.

Brique	Statut et choix
API	Existant : NestJS 11, Express, TypeScript strict ; conserver.
Interface	À construire en TypeScript ; choix de framework à consigner avant création.
Données	Proposé : PostgreSQL, migrations et stockage objet privé.
Recherche	Proposé : SQL/textuel puis pgvector après évaluation. Pas de Qdrant initial.
Traitements	Proposé : worker Node.js et Redis/BullMQ lors de l’ajout du pipeline.
IA	Adaptateur fournisseur à choisir : délai, coût, schéma et versions. Hermes non requis au MVP.

FLUX DE RÉFÉRENCE

Interface → API et autorisations → stockage privé + job → worker d’extraction → profil validé → comparaison → brouillon → export demandé par le recruteur.

Les longues opérations retournent un identifiant de traitement ; l’interface suit son état. Aucune donnée brute dans la file si une référence protégée suffit.

Modules métier proposés

identity, organizations, documents, profiles, missions, matching, drafts, usage et billing. Contrôleurs courts, règles dans les services, stockage et fournisseurs derrière des adaptateurs. Créer chaque module au moment de sa fonction.

Architecture progressive

Archive historique — Un socle modulaire, des évolutions justifiées par les mesures

ARCHIVÉ · HORS PÉRIMÈTRE B2C

Données et contrats durables

La cohérence des données prime sur un gain marginal de sérialisation.

Modèle logique

Organization et Membership définissent les accès. Document et ProfileVersion portent source et interprétation. MissionVersion fixe les critères. MatchResult et Draft référencent ces versions. Job et UsageEvent tracent exécution et consommation. Identifiants stables, dates et contraintes de relations entre données de la même organisation.

Isolation de bout en bout

- Déterminer l'organisation depuis une identité et une appartenance vérifiées ; contrôler requêtes, téléchargements et exports.
- Propager l'organisation aux jobs, caches, vecteurs et fichiers. Un préfixe de stockage n'est pas une autorisation.
- Tester identifiants devinés, recherche, reprise et export. Évaluer la sécurité SQL par ligne comme défense supplémentaire.
- Vérifier le rappel vectoriel avec filtres de cabinet contre une recherche exacte. [VECTOR]

Publication fiable

Créer le job durablement en base avec l'opération métier. Prévoir une boîte d'envoi transactionnelle si base et file peuvent diverger : un relais publie puis marque l'événement. La rediffusion reste possible ; le worker doit être idempotent. [JOBS]

VERSIONNER POUR EXPLIQUER

Un résultat référence document, profil, mission, modèle et méthode. Une modification produit une nouvelle version ; elle ne réécrit pas silencieusement une décision historique. Appliquer la rétention à cet historique.

[VECTOR] [pgvector](#) — [documentation officielle](#), [index et filtres](#) · consulté le 06/09/2026.

[JOBS] [BullMQ](#) — [tâches idempotentes](#) · consulté le 06/09/2026.

Architecture progressive

Archive historique — Un socle modulaire, des évolutions justifiées par les mesures

ARCHIVÉ · HORS PÉRIMÈTRE B2C

Déployer et diagnostiquer simplement

L'exploitation doit rester réalisable par l'équipe disponible.

Environnements et livraison

Séparer développement, préproduction et production. Le workflow CI du dépôt couvre lint, typage, tests et build ; exécution distante à activer sur le dépôt hébergé. Ajouter les tests métier avec les fonctions. API et worker déployables séparément, configuration externe et migrations compatibles avec retour applicatif.

Supervision

- Identifiant de corrélation entre requête, job et résultat ; journaux structurés sans CV ni jeton.
- Mesurer erreurs, file, temps et coûts ; affecter chaque alerte à un responsable.
- /health reste un contrôle de vie ; ajouter une readiness quand base et file existent.
- Tester restauration et purge après changement du stockage.

Modes dégradés

Une panne IA suspend la génération mais conserve la lecture. Pas de bascule vers un fournisseur non approuvé. Une panne de file est visible ; les jobs durables sont republiables. Un fichier invalide termine en erreur explicite, sans boucle de reprise.

DÉPLOIEMENT INITIAL PROPOSÉ

API et worker dans un environnement simple, données sauvegardées. Choisir hébergement et régions après budget et revue des flux. Kubernetes, NATS, gRPC et multi-région ne sont pas requis pour le pilote.

Objectifs internes du document 02 : RPO 24 h, RTO 4 h, à démontrer avant engagement. Préparer retour applicatif et compatibilité des migrations ; une sauvegarde n'est pas un rollback instantané.

Architecture progressive

Archive historique — Un socle modulaire, des évolutions justifiées par les mesures

ARCHIVÉ · HORS PÉRIMÈTRE B2C

Quand extraire un service

Une décision économique fondée sur un profilage reproductible.

Évolution	Condition avant décision
Parseur Rust	Parsing dominant le CPU malgré optimisation/isolément ; prototype mesuré sur le même corpus.
Orchestrateur Go	Limite de concurrence démontrée ; bénéfice supérieur au coût de maintenance.
Qdrant	Recherche insuffisante après réglage SQL/vectorel ; comparaison qualité/coût avec filtres tenant.
GPU dédié	Coût complet inférieur à l'API à qualité égale et occupation prudente.
gRPC ou autre bus	Besoin non satisfait par HTTP + file ; gain supérieur au coût opératoire.

Dossier de décision

Goulot, scénario, mesures avant/après, qualité, coûts, responsable, migration et retour arrière. Un langage compilé ne réduit pas automatiquement le temps du navigateur, du réseau ou d'un modèle distant.

Migration contrôlée

- Contrat versionné et tests communs ; une seule autorité d'écriture par donnée.
- Comparer hors production puis sur petite cohorte, avec retour possible.
- Rejouer isolation, suppression, quotas et idempotence.
- Documenter délais, annulation et reprises ; ne pas promettre « exactement une fois » sans traiter les effets de bord.

CRITÈRE FINAL

Résoudre un problème mesuré sans dégrader preuves, isolation ou support. Cette trajectoire n'implique aucun service spécialisé déjà implémenté.